Vysoké učení technické v Brně
Fakulta informačních technologií

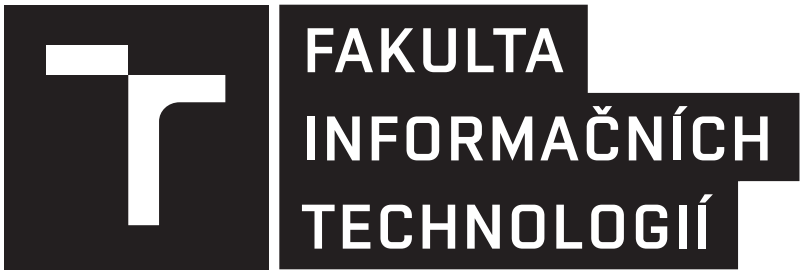

Dokumentace k projektu do předmětů IFJ a IAL

Implementace interpretu jazyka IFJ15

Tým *052*, varianta *a/2/II*

Vedoucí týmu:	Postolka Matěj	xposto02	25 %
Další členové:	Osadský Lukáš	xosads00	25 %
	Plaskoň Pavol	xplask00	25 %
	Pospíšil Pavel	xpospi88	25 %

Obsah

1 Úvod

Dokumentace popisuje implementaci interpretu jazyka IFJ15, který je podmnožinou jazyka C++11. Interpret se skládá ze čtyřech částí popsaných v následujících kapitolách.

- Lexikální analyzátor
- Syntaktický analyzátor
- Sémantický analyzátor
- Interpret

2 Práce v týmu

2.1 Rozdělení práce na jednotlivých částech

- Osadský Lukáš – Lexikální analyzátor
- Postolka Matěj – Sémantický a syntaktický analyzátor
- Pospíšil Pavel – Zpracování výrazů a volání funkcí, dokumentace
- Plaskoň Pavol – Interpret, vestavěné funkce

2.2 Průběh vývoje

Projekt je řešený čtyřčlenným týmem, bylo tedy potřebné zvolit vhodný systém správy zdrojových souborů. Přes téměř nulové zkušenosti většiny členů týmu jsme k těmto účelům využili verzovací systém `git` na privátním serveru vedoucího člena. Konzultace probíhaly jednou týdně, obsahovaly zhodnocení aktuálních výsledků a stanovení dalšího postupu. Nejdříve tedy každý člen pracoval sám, po několika týdnech práce proběhly dvě schůzky na kterých jsme programovali společně. V průběhu celého procesu členové týmu doplňovali krátké testovací ukázky kódu, kterými bylo následně možné, pomocí skriptu napsaného v jazyce `Python`, testovat dosavadní stabilitu celku. Při testování se nám též osvědčil nástroj `gcovr`.

3 Implementace interpretu jazyka IFJ15

3.1 Lexikální analýza

Lexikální analyzátor je vstupní částí interpretu. Je založen na deterministickém konečném automatu, jehož hlavním úkolem je čtení zdrojového souboru a na základě lexikálních pravidel jazyka rozdělit jednotlivé posloupnosti znaků souboru na lexikální části – lexémy.

Rozpoznané lexikální jednotky jsou reprezentovány strukturou `token`, která obsahuje informace o typu tokenu a jeho data. Data do tokenu jsou zapisována za pomoci funkcí z námi implementované knihovny `string.h`.

Vedlejším úkolem lexikální analýzy je odstraňování všech komentářů a bílých znaků, neboť nejsou podstatné v dalších krocích interpretace. Vstupní souboru může obsahovat dva typy komentářů – řádkový, uvozený znaky `//` a blokový ohraničený sekvencemi znaků `/*` a `*/`. Po ukončení čtení komentáře automat opět přejde do počátečního stavu.

Činnost lexikálního analyzátoru je přímo řízena syntaktickým analyzátorem, který postupně žádá o jednotlivé tokeny. Princip fungování lexikální analýzy reprezentuje příloha 4.A, ve které je zobrazeno její schéma.

3.2 Syntaktická a sémantická analýza

Syntaktický a sémantický analyzátor, neboli `parser`, představuje ústřední část naší implementace interpretu jazyka IFJ15. Parser se volá prakticky ihned po spuštění programu a přejímá řízení do doby, než dojde k úplnému zpracování zdrojového souboru.

3.2.1 Zpracování jazykových konstrukcí

Syntaktická analýza je implementována rekurzivním sestupem, který je řízen pravidly naší LL-gramatiky uvedenými v příloze 4.B. Neterminální symboly představují tokeny přijaté od lexikálního analyzátoru. Ten je volán přímo z parseru vždy, když je třeba zpracovat další token. Se syntaktickou analýzou je současně vykonávána také analýza sémantická. Při deklaraci nebo definici funkce se do globální tabulky symbolů ukládá datová struktura reprezentující danou funkci – jazyk IFJ15 podporuje v globálním prostoru pouze funkce.

V případě definice funkce poté dochází ke zpracování těla dané funkce. Přímo během rekurzivního sestupu se tak vykonávají všechny potřebné sémantické kontroly a naplňuje se lokální tabulka symbolů. Taktéž se generují vnitřní instrukce, které se ukládají do instrukčního seznamu příslušné funkce. Pokud se během syntaktické analýzy narazí na výraz, je řízení programu předáno modulu pro vyhodnocování výrazů `expr`, který pomocí precedenční analýzy provede vyhodnocení daného výrazu a poté předá řízení zpět parseru.

Po zpracování celého zdrojového souboru se provádí závěrečné sémantické kontroly. Kontroluje se například, zda došlo během zpracování zdrojového souboru k definici všech deklarovaných funkcí a přesná signatura funkce `main`. Tímto je syntaktická a sémantická analýza ukončena a parser předá řízení interpretu.

3.2.2 Zpracování výrazů a volání funkcí

Zpracování výrazů je voláno v několika rozličných situacích. Existují situace, kdy se však na místě výrazu může objevit volání funkce. Volání funkcí i zpracovávání výrazů jsou tedy v naší implementaci součástí jednoho modulu.

Zpracování výrazů řízené precedenční tabulkou uvedenou v příloze 4.C probíhá ve dvou krocích. V prvním kroku je za pomoci zásobníkové struktury výraz převeden z infixové na postfixovou notaci. V tomto kroku je kontrolována správná posloupnost operátorů, operandů a závorek.

V kroku druhém je vyhodnocena postfixová notace a vygenerovány příslušné instrukce. V této fázi běhu interpretu se kontroluje datová kompatibilita operandů a nastavují odvozené datové typy proměnným s modifikátorem `auto`.

Při výskytu volání funkce je mimo jiné kontrolována kompatibilita návratového typu funkce a typu proměnné pro přiřazení navrácené hodnoty.

3.3 Interpret

Interpret ke své práci využívá globální zásobník, lokální zásobník pro aktuální funkci a tabulky s rozptýlenými položkami pro proměnné. Každý blok příkazů interpretovaného programu má vlastní tabulku proměnných – zabezpečení viditelnosti proměnných pouze v rámci jejich bloku. Na začátku se v globální tabulce symbolů vyhledá funkce `main`, vytvoří se pro ni lokální rámec a instrukční ukazatel se nastaví na začátek instrukčního listu – jednosměrně vázaného lineárního seznamu. Přesun na další položku seznamu představuje přechod na další instrukci. Při instrukci skoku se instrukční ukazatel nastaví na danou instrukci `INS_LAB` označující návěští.

3.3.1 Volání funkcí

Před provedením volání funkce jsou její parametry uloženy na pomocný zásobník instrukcí `INS_PUSH_PARAM`. Dále se do globálního zásobníku uloží ukazatel na aktuální instrukci a aktuální rámec, vytvoří se nový lokální rámec a instrukční ukazatel se nastaví na začátek instrukčního listu volané funkce. Při návratu z funkce se její návratová hodnota uloží do vyhrazené proměnné ve struktuře reprezentující funkci v globální tabulce symbolů. Tím je interpret oddělen od režie návratových hodnot. Menší nevýhodou této implementace je generování návratové proměnné pro každou funkci. Vše je zabezpečeno při generování kódu. Z globálního rámce se načte původní rámec a instrukce, odkud byla funkce volána, a pokračuje se instrukcí další.

3.4 Datové struktury

3.4.1 Zásobník

Zásobník je dynamická datová struktura. Položkami zásobníku jsou ukazatele na typ `void`, což umožňuje jeho široké využití. Uplatňuje se v `parseru` i `interpretu`. Má důležitou úlohu například při převodu infixového zápisu výrazů na postfixový.

3.4.2 Řetězec

V naší implementaci je řetězec v podstatě `vektor`, nebo-li dynamické pole znaků. Dle potřeby mění svoji kapacitu. Námi implementovaný datový typ `TString` se značně liší od datového typu `string` ve vyšších programovacích jazycích.

3.4.3 Tabulka s rozptýlenými položkami

Tato datová struktura je použitá pro tabulky symbolů. Její výhodou je rychlost vyhledávání položek. Základem je pole ukazatelů na jednotlivé položky. Položky obsahují svůj klíč, data a ukazatel na další položku, aby mohly být propojené v jednosměrně explicitně vázaný lineární seznam – seznam synonym. V případě ideální hashovací funkce není propojení v seznam potřebné a čas přístupu k položkám je konstantní. Nalezení takové funkce není triviální. Zvolili jsme dostatečnou funkci `sbdm`[1]. V případě konfliktu se čas nalezení položky prodlužuje o dobu prohledání seznamu synonym.

3.5 Algoritmy

Následující kapitola se zabývá dvěma nejzajímavějšími algoritmy naší implementace, první z nich slouží pro řazení, druhý pro vyhledávání podřetězce v řetězci.

3.5.1 Řadící algoritmus – Heap Sort

Heap – hromada je struktura stromového typu. Nejčastěji, i v naší implementaci, se jedná o uspořádaný binární strom. Významnou operací nad hromadou je `siftDown` – prosetí, která zrekonstruuje hromadu porušenou v kořeni. Prvek v kořeni se postupně přesune na správné místo. V nejhorším případě (přesun z kořene až do listu) bude složitost $\log_2 n$. Podstatou řazení je implementace hromady polem velikosti N, kde uzel umístněný na indexu i má svého levého syna na indexu $2i + 1 - base$ [1] a pravého syna na indexu $2i + 2 - base$. Index nejpravějšího neterminálního uzlu na nejnižší úrovni je $N/2 - 1 + base$. Vlastní cyklus heap sortu má lineární složitost, přičemž v každém kroku se vymění kořen s posledním prvkem a *proseje* se hromada. Tím dostáváme linearitmickou časovou složitost.

3.5.2 Vyhledávaní podřetězce v řetězci – Knuth-Morris-Pratt

Vyhledání podřetězce v řetězci ve vestavěné funkci `find` je řešeno algoritmem Knuth-Morris-Pratt. Základem algoritmu je vytvoření masky, tzv. `Fail vector`. Jedná se o pole celých čísel, délka pole je totožná s délkou hledaného textu. Ke každému písmenu hledaného podřetězce je přiřazeno číslo, které určuje index pro začátek dalšího hledání v případě neshody znaků.

[1] *base* – index první položky pole

4 Přílohy

4.A Diagram konečného automatu lexikální analýzy [2]

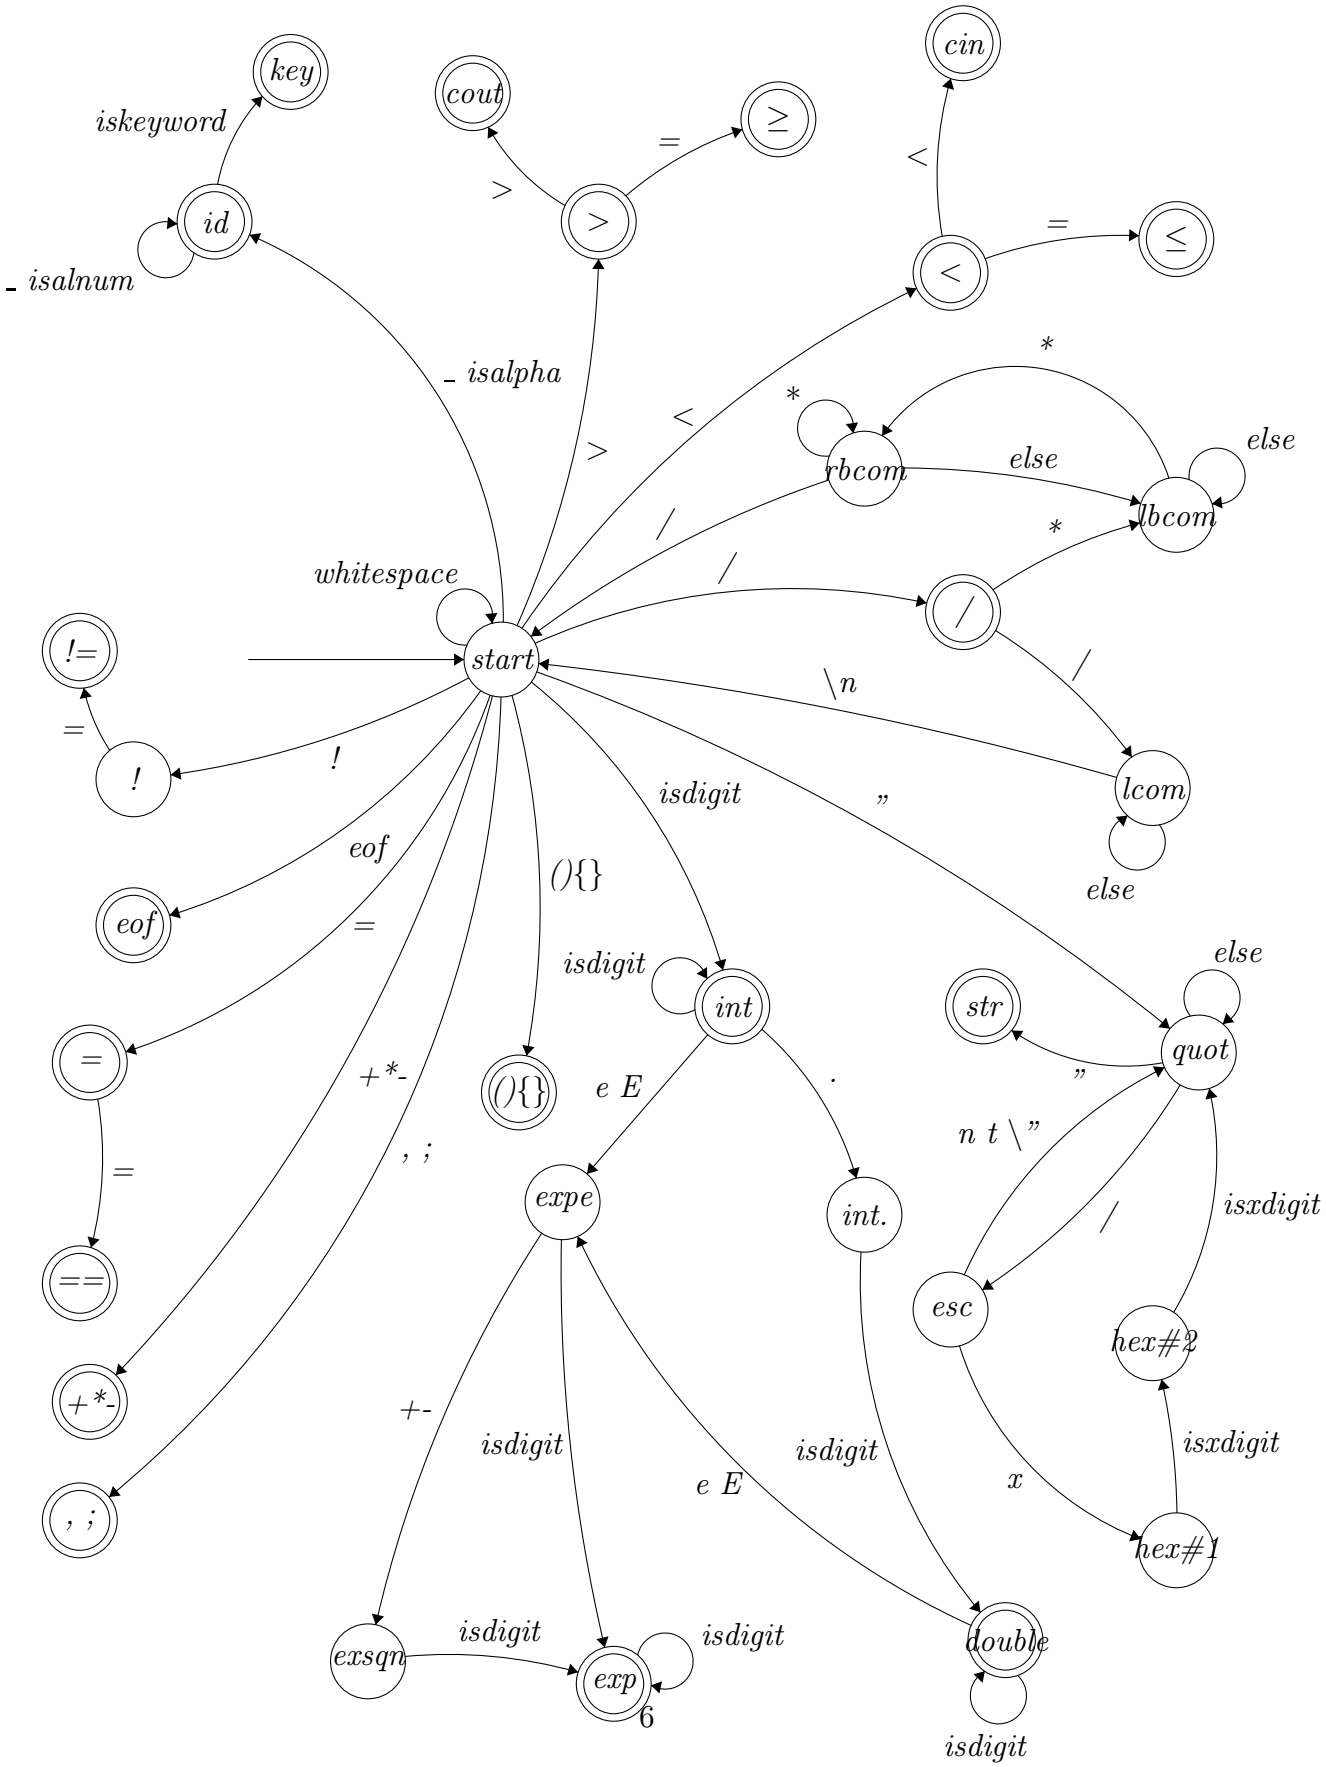

4.B LL-gramatika

4.B.1 Část první

```
PROG->FUNCTION_DECL PROG
PROG->eps
FUNCTION_DECL->DATA_TYPE t_identifier t_lround_bracket FUNC_DECL_PARAMS t_rround_bracket NESTED_BLOCK
DATA_TYPE->t_int
DATA_TYPE->t_double
DATA_TYPE->t_string
FUNC_DECL_PARAMS->DATA_TYPE t_identifier FUNC_DECL_PARAMS_NEXT
FUNC_DECL_PARAMS_NEXT->t_comma FUNC_DECL_PARAMS
FUNC_DECL_PARAMS->eps
FUNC_DECL_PARAMS_NEXT->eps
NESTED_BLOCK->t_lcurly_bracket NBC t_rcurly_bracket
NBC->DECL_OR_ASSIGN NBC
DECL_OR_ASSIGN->DATA_TYPE t_identifier DECL_ASSIGN t_semicolon
DECL_OR_ASSIGN->t_auto t_identifier t_assign EXPRESSION t_semicolon
DECL_ASSIGN->t_assign EXPRESSION
DECL_ASSIGN->eps
NBC->FCALL_OR_ASSIGN NBC
FCALL_OR_ASSIGN->t_identifier FOA_PART2
FOA_PART2->t_lround_bracket FUNCTION_CALL_PARAMS t_rround_bracket t_semicolon
FOA_PART2->t_assign EXPRESSION t_semicolon
HARD_VALUE->t_int_value
HARD_VALUE->t_double_value
HARD_VALUE->t_string_value
FUNCTION_CALL_PARAMS->FUNCTION_CALL_PARAM FUNCTION_CALL_PARAMS_NEXT
FUNCTION_CALL_PARAMS->eps
FUNCTION_CALL_PARAM->t_identifier
FUNCTION_CALL_PARAM->HARD_VALUE
FUNCTION_CALL_PARAMS_NEXT->t_comma FUNCTION_CALL_PARAMS
FUNCTION_CALL_PARAMS_NEXT->eps
```

4.B.2 Část druhá

```
NBC->BUILTIN_CALL NBC
BUILTIN_CALL->BUILTIN_FUNC t_lround_bracket FUNCTION_CALL_PARAMS t_rround_bracket t_semicolon
BUILTIN_FUNC->token_bf_length
BUILTIN_FUNC->token_bf_substr
BUILTIN_FUNC->token_bf_concat
BUILTIN_FUNC->token_bf_find
BUILTIN_FUNC->token_bf_sort
NBC->IF_STATEMENT NBC
IF_STATEMENT->t_if t_lround_bracket EXPRESSION t_rround_bracket NESTED_BLOCK ELSE_STATEMENT
ELSE_STATEMENT->t_else NESTED_BLOCK
ELSE_STATEMENT->eps
NBC->COUT NBC
COUT->t_cout t_cout_bracket COUT_OUTPUT COUT_NEXT t_semicolon
COUT_OUTPUT->t_identifier
COUT_OUTPUT->HARD_VALUE
COUT_NEXT->t_cout_bracket COUT_OUTPUT COUT_NEXT
COUT_NEXT->eps
NBC->CIN NBC
CIN->t_cin t_cin_bracket t_identifier CIN_NEXT t_semicolon
CIN_NEXT->t_cin_bracket t_identifier CIN_NEXT
CIN_NEXT->eps
NBC->FOR_STATEMENT NBC
FOR_STATEMENT->t_for t_lround_bracket FOR_DECLARATION FOR_EXPR FOR_ASSIGN t_rround_bracket NESTED_BLOCK
FOR_DECLARATION->DATA_TYPE t_identifier DECL_ASSIGN t_semicolon
FOR_DECLARATION->t_auto t_identifier t_assign EXPRESSION t_semicolon
FOR_EXPR->EXPRESSION t_semicolon
FOR_ASSIGN->t_identifier t_assign EXPRESSION
NBC->NESTED_BLOCK NBC
NBC->RETURN
RETURN->t_return EXPRESSION t_semicolon
NBC->eps
```

4.C Precedenční tabulka

Stack \ Input	+	-	*	/	(	)	id	<	>	<=	>=	==	!=
+	>	>	<	<	<	>	<	>	>	>	>	>	>
-	>	>	<	<	<	>	<	>	>	>	>	>	>
*	>	>	>	>	<	>	<	>	>	>	>	>	>
/	>	>	>	>	<	>	<	>	>	>	>	>	>
(	<	<	<	<	<	=	<	<	<	<	<	<	<
)	>	>	>	>	!	>	!	>	>	>	>	>	>
id	>	>	>	>	!	>	!	>	>	>	>	>	>
<	<	<	<	<	<	>	<	>	>	>	>	>	>
>	<	<	<	<	<	>	<	>	>	>	>	>	>
<=	<	<	<	<	<	>	<	>	>	>	>	>	>
>=	<	<	<	<	<	>	<	>	>	>	>	>	>
==	<	<	<	<	<	>	<	<	<	<	<	>	>
!=	<	<	<	<	<	>	<	<	<	<	<	>	>

4.D Instrukční sada trojadresného kódu

4.D.1 Část první

- `INS_ASSIGN dest, src1`
  přiřadí hodnotu proměnné *src1* do *dest*
- `INS_ADD dest, src1, src2`
  sčítá *src1* a *src2*, výsledek uloží do *dest*
- `INS_SUB dest, src1, src2`
  odečítá *src1* od *src2*, výsledek uloží do *dest*
- `INS_MUL dest, src1, src2`
  vynásobí *src1* a *src2*, výsledek uloží do *dest*
- `INS_DIV dest, src1, src2`
  vydělí *src2* a *src1*, výsledek uloží do *dest*
- `INS_EQ dest, src1, src2`
  testuje rovnost *src1* a *src2*, výsledek uloží do *dest*
- `INS_NEQ dest, src1, src2`
  testuje nerovnost *src1* a *src2*, výsledek uloží do *dest*
- `INS_GREATER dest, src1, src2`
  testuje, zda je *src1* větší než *src2*, výsledek uloží do *dest*
- `INS_GREATEQ dest, src1, src2`
  testuje, zda je *src1* větší nebo roven *src2*, výsledek uloží do *dest*
- `INS_LESSER dest, src1, src2`
  testuje, zda je *src1* menší než *src2*, výsledek uloží do *dest*
- `INS_LESSEQ dest, src1, src2`
  testuje, zda je *src1* menší nebo roven *src2*, výsledek uloží do *dest*
- `INS_JMP label`
  nepodmíněný skok na návěští *label*
- `INS_CJMP cond label`
  podmíněný skok na návěští *label* na základě hodnoty *cond*
- `INS_LAB label`
  definice návěští *label* pro skok
- `INS_PUSH_PARAM src`
  uloží na pomocný zásobník parametr *src* pro volání funkce
- `INS_CALL func`
  volání funkce *func*

4.D.2 Část druhá

- `INS_RET`
  ukončení provádení funkce
- `INS_PUSH_TAB src1`
  vytvoření nového rámce pro vnořený blok *src1*
- `INS_POP_TAB src1`
  zrušení rámce vnořeného bloku *src1*
- `INS_LENGTH dest, src1`
  volání vestavěné funkce *length* s parametrem *src1*, výsledek uloží do *dest*
- `INS_SUBSTR dest`
  volání vestavěné funkce *substr* s předem uloženými parametry, výsledek uloží do *dest*
- `INS_CONCAT dest, src1, src2`
  volání vestavěné funkce *concat* s parametry *src1* a *src2*, výsledek uloží do *dest*
- `INS_FIND dest, src1, src2`
  volání vestavěné funkce *find* s parametry *src1* a *src2*, výsledek uloží do *dest*
- `INS_SORT dest, src1`
  volání vestavěné funkce *sort* s parametrem *src1*, výsledek uloží do *dest*
- `INS_CIN src1`
  načítá do *src1* hodnotu ze standardního vstupu
- `INS_COUT dest`
  vypíše na standardní výstup *dest*

5 Reference

[1] *Hash Functions* [online]. [cit. 2015-12-13]. Dostupné z: `http://www.cse.yorku.ca/~oz/hash.html`

[2] WALLACE, E. *Finite State Machine Designer* [online]. 2010 [cit. 2015-12-13]. Dostupné z: `http://madebyevan.com/fsm/`

[3] Prof. Ing. Jan Maxmilián Honzík, CSc. *Algoritmy IAL: Sudijní opora* [online]. Verze 14R. 2015-12-11 [cit. 2015-12-13]. Dostupné z: `https://wis.fit.vutbr.cz/FIT/st/course-files-st.php/course/IAL-IT/texts/Opora-IAL-2014-verze-14R.pdf`